Hanz Franklyn B.W

RETAIL ANALYTICS PROJECT

End-to-end Data Analytics Portfolio Project menggunakan dataset Online Retail II

LinkedIn

GitHub

Portfolio Project

2026

CONTENTS

Beberapa tahapan yang akan dibahas dalam presentasi. Meliputi seluruh proses proyek mulai dari konteks bisnis awal sampai rekomendasi bisnis untuk tindak lanjut.

01 Business Background
Konteks bisnis, *stakeholder*, dan pertanyaan analitik yang memandu seluruh analisis

02 Dataset & Metodologi
Overview *dataset*, proses *data cleaning*, *tools* yang digunakan, serta analisis yang dilakukan

03 Key Findings: Customer Analytics
Segmentasi pelanggan melalui RFM, *k-means clustering*, dan *cohort retention analysis*

04 Key Findings: Sales Analytics
Tren *revenue*, performa produk, dan analisis *cancellation* selama periode tertentu (2009 - 2011)

05 Rekomendasi Bisnis
6 action items berbasis data untuk tindak lanjut tim *Management* dan *Marketing*

Business Background

Perusahaan adalah UK-based online retail yang menjual barang secara *non-store*. Mayoritas pelanggan merupakan *wholesaler* yang melakukan pembelian dalam jumlah besar, dengan jangkauan operasional internasional di 41 negara.

Adapun masalah bisnis bisa dirangkum menjadi dua poin penting berikut:

01 *"Siapa pelanggan paling valuable kami, dan bagaimana cara mempertahankan mereka?"*

02 *"Bagaimana tren performa penjualan kami, dan di mana peluang untuk meningkatkannya?"*

Stakeholder & KPI

Stakeholder dan kebutuhannya dalam kasus proyek ini adalah sebagai berikut:

- C-Level/Management: Visibility terhadap performa bisnis secara keseluruhan
- Tim Marketing: Segmentasi pelanggan untuk strategi retensi dan targeting

KPI yang diukur dalam analisis adalah sebagai berikut:

- Total Revenue
- Monthly Revenue Growth (MoM)
- Average Order Value (AOV)
- Cancellation Rate
- Customer Retention Rate
- RFM Segment Distribution
- Cohort Retention Rate

Dataset & Metodologi

1.067.371
Transaksi

5.878
Customer

41
Negara

2 Tahun
Periode Data

Data Cleaning Summary

- Sebelum cleaning : 1.067.371 baris
- Sesudah cleaning : 779.425 baris
- Data dipisahkan : 42.444 baris (cancelled + retur)
- Data dihapus : 245.502 baris (missing value, data duplikat, dan data dengan price ≤ 0)

Workflow

01 Business Understanding
02 Data Collection
03 Data Cleaning
04 SQL Querying
05 Exploratory Data Analysis
06 Customer Analytics
07 Sales Analytics
08 Visualization (Dashboard)
09 Project Documentation

KPI Summary

£17.374.804	36.969	£469,98	5.878
Total Revenue	Total Orders	Avg. Order Value	Total Customers

Konteks Tambahan

- 18,32% Cancellation Rate dari seluruh order, namun dampak terhadap revenue hanya 8%, yang berarti pembatalan didominasi oleh order-order bernilai kecil.
- Total revenue £17,37 juta dihasilkan dari hampir 37 ribu orders selama dua tahun, dengan rata-rata nilai transaksi £470 per order dan konsisten sepanjang periode.
- UK dominan dengan 91.4% dari total customers.

Catatan Penting

- Data Desember 2011 tidak penuh, revenue Q4 2011 aktual lebih besar dari yang terdata.
- 22.8% Customer ID tidak tercatat, kemungkinan transaksi guest checkout yang tidak tercatat dengan baik.

HASIL ANALISIS

Analisis secara garis besar mencakup ***customer analytics*** (segmentasi RFM, *k-means clustering*, *cohort analysis*) serta **sales analytics** (*revenue analysis, product analysis,* dan *cancellation analytics*).

Customer Analytics Key Findings

RFM Segmentation

- **Champions** (22.1%) mendominasi revenue dengan Avg Monetary **£9.143**, hampir **3x** lipat segmen Loyal Customers.
- **At Risk** (10.5%)** adalah prioritas retensi utama, pernah bertransaksi besar (**£2.444**) tapi sudah **359** hari tidak aktif.
- **Need Attention + Hibernating + Lost** = **34.3%** dari total pelanggan, lebih dari sepertiga pelanggan sudah tidak aktif.
- **New Customers** (7.5%) memiliki Avg Monetary **£885** meski baru bergabung, potensi untuk menjadi Loyal Customers.

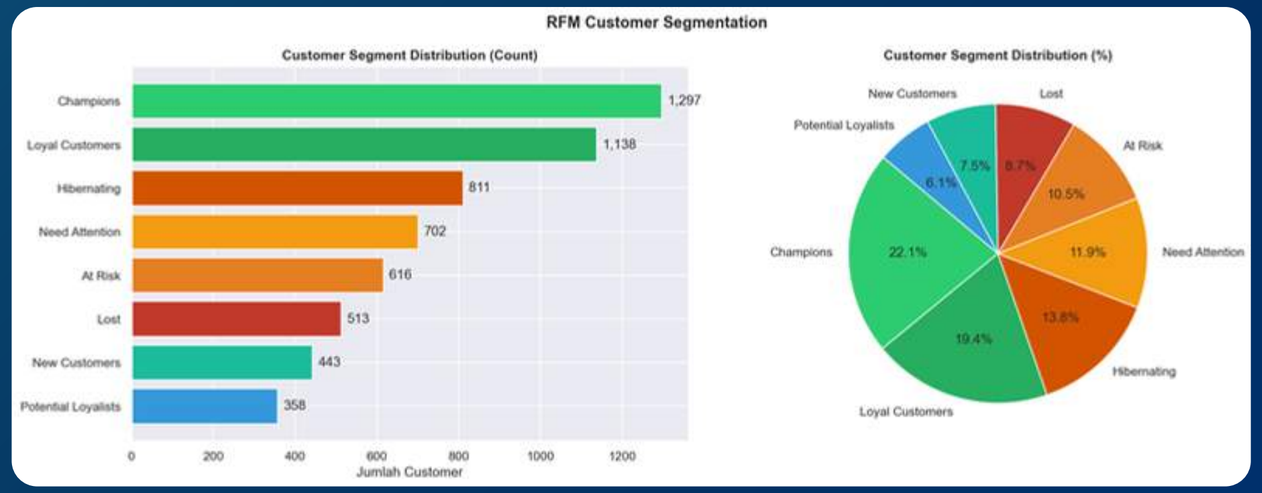

Segment	Total_Customers	Avg_Recency	Avg_Frequency	Avg_Monetary
Champions	1297	19.96	17.11	9143.86
At Risk	616	359.51	5.62	2444.23
Loyal Customers	1138	73.38	5.95	2255.40
New Customers	443	28.11	1.46	885.48
Need Attention	702	270.46	1.96	630.14
Potential Loyalists	358	79.72	2.70	591.26
Lost	513	568.23	1.00	344.32
Hibernating	811	407.17	1.29	271.26

Customer Analytics Key Findings

K-Means Clustering

- **High Value & Promising** memiliki Recency hampir sama (**27-28 hari**), yang menjadi pembeda adalah Frequency (**19.3 vs 3.0**) dan pada Monetary (**£10.731 vs £857**), menunjukkan bahwa clustering berhasil memisahkan dua profil aktif berbeda.
- **Inactive** adalah cluster terbesar (**1.973 customers**), lebih dari **33%** pelanggan sudah tidak aktif lebih dari 1 tahun.
- **At Risk** masih memiliki nilai Monetary yang signifikan (**£1.948**), masih layak untuk diprioritaskan dalam *win-back campaign*.

Cluster	Jumlah	Avg Recency	Avg Frequency	Avg Monetary
High Value	1.196	27.71 hari	19.28x	£10.731
Promising	1.250	28.30 hari	3.05x	£857
At Risk	1.459	230.07 hari	5.06x	£1.948
Inactive	1.973	394.95 hari	1.38x	£317

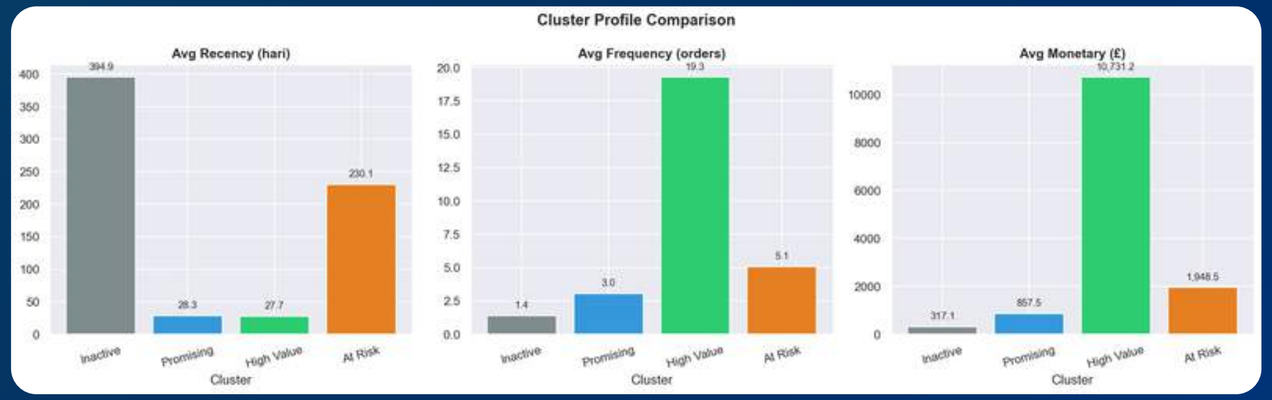

Customer Analytics Key Findings

Cohort Analysis

- Retention bulan ke-1 berkisar **15–35%**, yang artinya 65–85% pelanggan tidak kembali di bulan berikutnya. Umum untuk bisnis wholesale online.
- Cohort Desember 2009 paling loyal, retention stabil di **25–45%** hingga bulan ke-24, indikasi dari pelanggan inti yang established.
- Peak season effect terlihat di diagonal heatmap, retention melonjak di bulan **Oktober–November** lintas cohort, yang membuktikan peak season mendorong returning customers, bukan hanya new customers.
- Cohort Desember = one-time buyers, retention bulan ke-1 hanya **9.2%** (2010-12), pelanggan holiday season cenderung tidak kembali.

Sales Analytics Key Findings

Revenue Analysis

- Peak revenue konsisten di November, dimana Nov 2010: **£1,166,460** dan Nov 2011: **£1,156,205**.
- Pada bulan Desember selalu turun tajam, dengan MoM Growth pada Des 2010: **-51.1%**, dan MoM Growth pada Des 2011: **-55.3%**.
- Lonjakan revenue terbesar pada Sep 2011, dengan MoM Growth **+47.6%.** Momentum terkuat sepanjang periode, tepat sebelum peak season pada Q4.
- Revenue tumbuh secara konsisten dengan pola seasonal yang dapat diprediksi, sehingga dapat memudahkan untuk *perencanaan inventory dan marketing*.

Sales Analytics Key Findings

Revenue Analysis

- Q4 selalu tertinggi dengan 2010 Q4: **£2,769,995** dan 2011 Q4: **£2,709,056**. Pola konsisten dimana Q4 selalu menghasilkan revenue terbesar. Perlu dicatat bahwa data Q4 2011 tidak penuh.
- 2011 tumbuh di 3 dari 4 kuartal, dimana Q2, Q3, Q4 2011 semuanya lebih tinggi dari 2010. Hanya Q1 2011 yang turun YoY (**£1.61M vs £1.76M**).
- Nilai transaksi konsisten dengan AOV stabil di **£400–£575** sepanjang periode, pelanggan tidak mengurangi nilai pembelian.
- Tren AOV positif di 2011, AOV pada H2 2011 *cenderung meningkat*. Pelanggan memesan dalam jumlah besar menjelang akhir periode.

Sales Analytics Key Findings

Product Analysis

- REGENCY CAKESTAND 3 TIER (**£277.656**) adalah produk revenue tertinggi dengan **3.317** orders.
- PAPER CRAFT, LITTLE BIRDIE (**£168.470, 1 order**), single bulk order dari satu wholesaler, bukan indikator performa produk yang sebenarnya.
- **Top 21.7%** produk menghasilkan **80%** revenue, sedangkan sisa **~78.3%** produk (**4.100+** produk) hanya berkontribusi **20%** revenue, kandidat untuk *evaluasi dan rasionalisasi portofolio produk*.
- Bottom 10 produk memiliki revenue di bawah **£25** meski sudah memiliki **10+** orders. Harga per unit sangat rendah, perlu evaluasi apakah masih layak untuk dipertahankan.

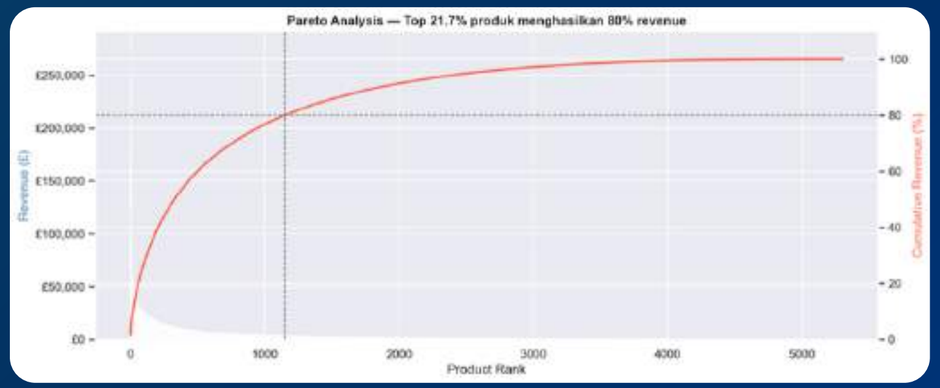

Sales Analytics Key Findings

Cancellation Analysis

- Cancellation rate sebesar **18.32%** (orders), hampir 1 dari 5 orders dibatalkan, namun hanya **8.08%** dari total revenue. Cancellation didominasi order nilai kecil, bukan order besar.
- **2.572 customers** (43% dari total) pernah melakukan cancellation setidaknya sekali.
- Tren cancellation rate menurun dari 2010 → 2011 dari kisaran **20-23%** turun ke **14–17%** di akhir 2011, yang dapat mengindikasikan adanya perbaikan operasional yang signifikan.

Sales Analytics Key Findings

Cancellation Analysis

- Japan (**41.1%**) memiliki cancellation rate tertinggi dengan lebih dari dua kali rata-rata (**18.3%**), kemungkinan ada *masalah dalam pengiriman internasional atau ekspektasi produk yang tidak terpenuhi.*
- Netherlands (**8.4%**) adalah negara dengan cancellation rate terendah, pelanggan paling konsisten dan reliable.
- **11 dari 18** negara berada di bawah weighted average (**18.3%**), masalah cancellation terkonsentrasi di segelintir negara saja.
- REGENCY CAKESTAND 3 TIER (**341 cancellations**) adalah produk paling sering dibatalkan sekaligus produk dengan revenue tertinggi. Ini dapat mengindikasikan *masalah inventory management pada produk high-demand.*

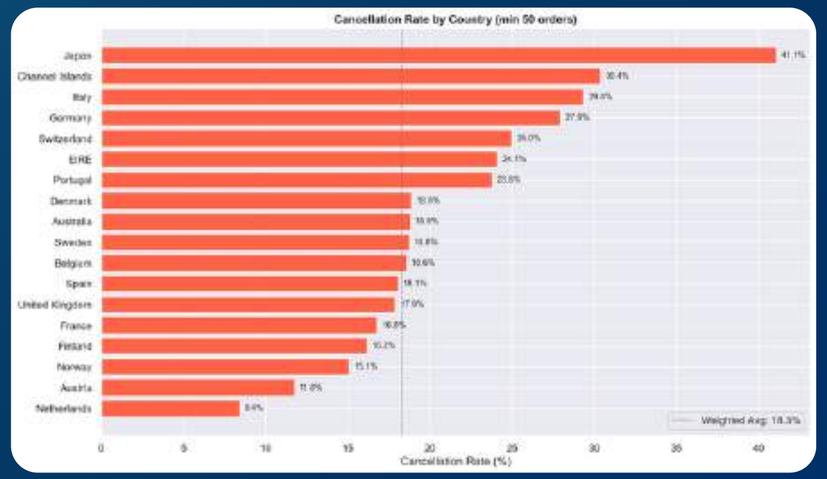

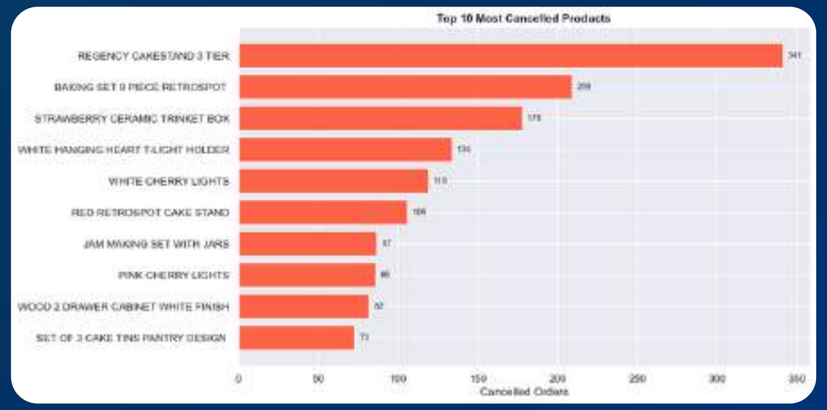

Business Recommendations

01 Win-Back Campaign

Target: Marketing

Temuan: At Risk segment (616 customers) memiliki rata-rata monetary £2.444, pernah aktif tapi sudah 359 hari tidak bertransaksi.
Rekomendasi: Luncurkan win-back campaign dengan penawaran eksklusif sebelum berpindah ke segmen Lost yang lebih sulit di-recover.

02 Champions Loyalty Program

Target: Marketing

Temuan: Champions (1.297 customers, 22.1%) adalah segment paling valuable dengan rata-rata monetary £9.143, hampir 3x Loyal Customers.
Rekomendasi: Buat loyalty program dan berikan early access produk baru untuk mempertahankan segment ini agar tidak turun ke Loyal atau At Risk.

03 Pre-Season Campaign

Target: Marketing

Temuan: Cohort analysis menunjukkan adanya spike retention di Oktober–November lintas semua cohort, peak season mendorong returning customers, bukan hanya new customers.
Rekomendasi: Mulai re-engagement campaign di periode Agustus–September untuk mengaktifkan kembali pelanggan Hibernating dan Need Attention sebelum peak season dimulai.

Business Recommendations

04 Inventory Management

Target: Management

Temuan: REGENCY CAKESTAND 3 TIER adalah produk #1 by revenue (£277K) sekaligus #1 most cancelled (341 cancellations), pola yang sama terlihat di WHITE HANGING HEART (#2)
Rekomendasi: Prioritaskan safety stock untuk top 10 produk high-demand agar order tidak dibatalkan.

05 Japan Market Investigation

Target: Management

Temuan: Japan memiliki cancellation rate 41.1%, ini lebih dari 2x weighted average global (18.3%) dan jauh di atas negara manapun dalam dataset.
Rekomendasi: Investigasi pengalaman pelanggan Jepang, apakah masalah pada pengiriman internasional, ekspektasi produk, atau faktor lainnya.

06 Portfolio Rationalization

Target: Management

Temuan: Pareto analysis menunjukkan top 21.7% produk (~1.150 SKU) menghasilkan 80% revenue, 78.3% produk lainnya hanya berkontribusi 20% revenue dengan biaya operasional penuh.
Rekomendasi: Evaluasi bottom performer dan pertimbangkan untuk discontinue produk yang tidak efisien agar sumber daya dapat lebih difokuskan pada SKU yang paling bernilai.

Kesimpulan

Analisis terhadap data transaksi Online Retail II selama dua tahun menghasilkan empat temuan utama, diantaranya:

- Pertama, bisnis menghasilkan total revenue **£17.37 juta** dengan pola seasonal yang sangat konsisten, **Q4** selalu menjadi puncak dan **Q1** selalu terendah di kedua tahun, *memberikan dasar yang kuat untuk perencanaan bisnis ke depan*.
- Kedua, segmen **Champions** yang mencakup **22.1%** pelanggan menghasilkan rata-rata **£9.143 per customer,** hampir tiga kali lipat segment di bawahnya, *menjadikan retensi segment ini sebagai prioritas utama.*
- Ketiga, meskipun cancellation rate mencapai **18.32% per orders**, dampaknya terhadap revenue hanya **8%** dan trennya konsisten menurun sepanjang 2011, *menunjukkan perbaikan operasional yang nyata.*
- Keempat, hanya **21.7%** dari total produk yang menghasilkan **80%** revenue. Fokus pada **~1.150 SKU** terpenting ini adalah merupakan *kunci efisiensi portofolio ke depan.*

Next Steps

Proyek ini membangun fondasi analisis deskriptif yang menjawab pertanyaan "apa yang terjadi". Langkah selanjutnya adalah bergerak ke analisis prediktif untuk menjawab "apa yang akan terjadi" dan "apa yang sebaiknya dilakukan". Adapun langkah yang dapat dilakukan adalah:

- Pertama, **membangun model revenue forecasting** untuk mendukung perencanaan inventory dan target penjualan secara lebih akurat
- Kedua, **menguji efektivitas rekomendasi bisnis melalui A/B testing**, mulai dari win-back campaign hingga pre-season re-engagement.
- Ketiga, **mengembangkan dashboard** yang mencakup semua hasil analisis dengan integrasi berbagai dataset yang sudah dibuat sehingga memungkinkan opsi filter.

THANK YOU

Keep scrolling for datasets, notebooks, and other appendices.

Appendix A - Data Cleaning Notes

Kondisi Awal Data

- Total baris: 1.067.371 | Total kolom: 8
- Missing Customer ID: 243.007 baris (22.8%)
- Missing Description: 4.382 baris (0.4%)
- Duplikat: 34.335 baris (3.2%)
- Cancelled (prefix 'C'): 19.494 baris
- Quantity negatif: 22.950 baris
- Price = 0 / negatif: 6.207 baris

Langkah Data Cleaning

- Pisahkan transaksi cancelled dan retur
- Drop missing Customer ID & Description
- Drop duplikat
- Drop Price = 0 & negatif
- Convert InvoiceDate → datetime
- Convert Customer ID → string
- Tambah kolom baru: TotalPrice, Year, Month, DayOfWeek

Kondisi Akhir Data

- Total baris: 779.425 | Total kolom: 12
- Missing values: 0
- Output: cleaned_data.csv, cancelled_transactions.csv, return_transactions.csv, retail.db
- Data cleaning notebook: **01_data_cleaning.ipynb**
- Raw dataset: **Link**
- Output datasets: **Link**

Appendix B – RFM Segmentation Details

Metodologi (Link Notebook)

- Recency: hari sejak transaksi terakhir
- Frequency: jumlah invoice unik per customer
- Monetary: total revenue per customer
- Scoring: quintile 1–5 per dimensi (5 = terbaik)

Performa Segmen

Segmen	Jumlah	Avg Recency	Avg Frequency	Avg Monetary
Champions	1.297	19.96 hari	17.11x	£9.143
Loyal Customers	1.138	73.38 hari	5.95x	£2.255
Potential Loyalists	358	79.72 hari	2.70x	£591
New Customers	443	28.11 hari	1.46x	£885
Need Attention	702	270.46 hari	1.96x	£630.14
Hibernating	811	407.17 hari	1.29x	£271
At Risk	616	359.51 hari	5.62x	£2.444
Lost	513	568.23 hari	1.00x	£344

Definisi Segmen

```python
def rfm_segment(row):
    r = int(row['R_Score'])
    f = int(row['F_Score'])
    m = int(row['M_Score'])

    if r >= 4 and f >= 4 and m >= 4:
        return 'Champions'
    elif r >= 3 and f >= 3 and m >= 3:
        return 'Loyal Customers'
    elif r >= 4 and f <= 2:
        return 'New Customers'
    elif r >= 3 and f >= 2 and m >= 2:
        return 'Potential Loyalists'
    elif r <= 2 and f >= 3 and m >= 3:
        return 'At Risk'
    elif r == 1 and f == 1:
        return 'Lost'
    elif r <= 2 and f <= 2 and m <= 2:
        return 'Hibernating'
    else:
        return 'Need Attention'
```

Appendix C - K-Means Clustering Details

Data Preparation untuk Clustering

Sebelum melakukan clustering, data RFM perlu dipersiapkan terlebih dahulu karena dua alasan utama:

1. Data RFM kita memiliki distribusi yang sangat right-skewed:
   - Sebagian besar pelanggan memiliki Frequency & Monetary yang rendah
   - Segelintir wholesaler besar memiliki nilai yang sangat ekstrem
   - Contoh: Monetary max = £580.987, jauh di atas mean £2.955
2. K-Means bekerja berdasarkan jarak Euclidean, outlier ekstrem dapat menarik centroid cluster ke arahnya dan menghasilkan cluster yang tidak representatif.

Maka untuk data RFM ini akan diberlakukan log transformation guna mengompres nilai-nilai ekstrem secara proporsional sehingga distribusi menjadi lebih simetris tanpa membuang data apapun.

Link **notebook** dan **dataset cluster_profile.csv**

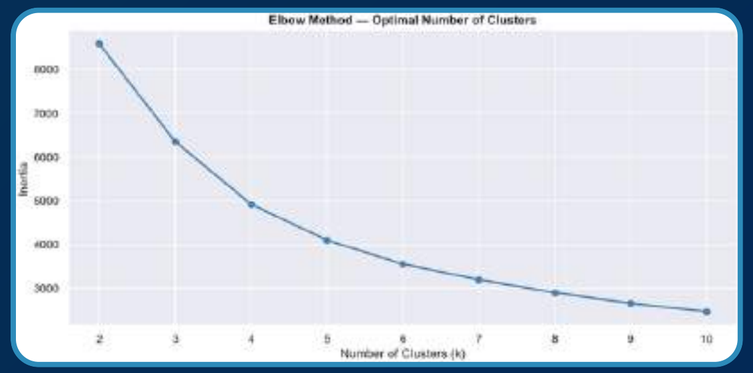

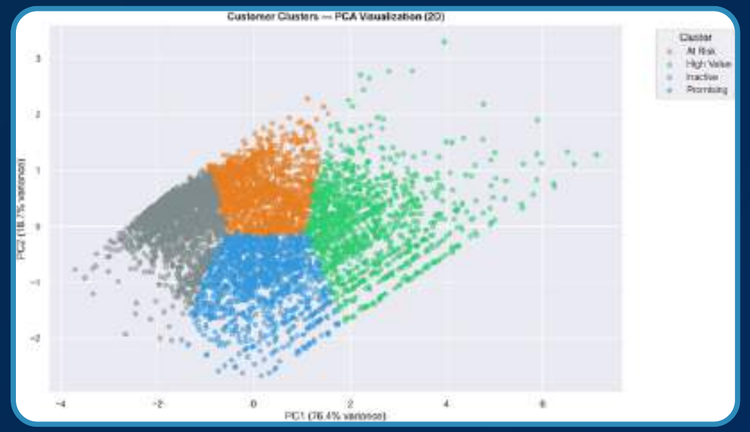

Appendix D - Cohort Heatmap Lengkap

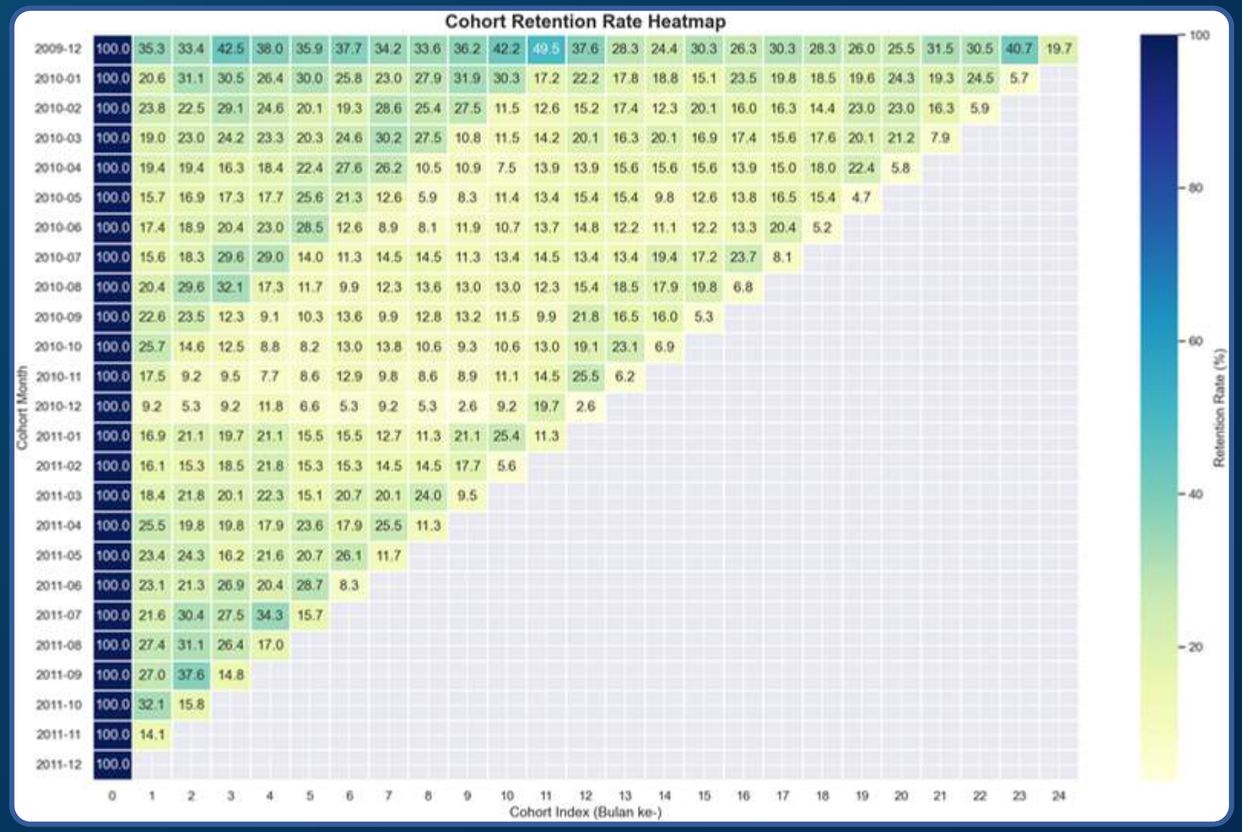

Cohort Month	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24
2009-12	100.0	35.3	33.4	42.5	38.0	35.9	37.7	34.2	33.6	36.2	42.2	49.5	37.6	28.3	24.4	30.3	26.3	30.3	28.3	26.0	25.5	31.5	30.5	40.7	19.7
2010-01	100.0	20.6	31.1	30.5	26.4	30.0	25.8	23.0	27.9	31.9	30.3	17.2	22.2	17.8	18.8	15.1	23.5	19.8	18.5	19.6	24.3	19.3	24.5	5.7	
2010-02	100.0	23.8	22.5	29.1	24.6	20.1	19.3	28.6	25.4	27.5	11.5	12.6	15.2	17.4	12.3	20.1	16.0	16.3	14.4	23.0	23.0	16.3	5.9		
2010-03	100.0	19.0	23.0	24.2	23.3	20.3	24.6	30.2	27.5	10.8	11.5	14.2	20.1	16.3	20.1	16.9	17.4	15.6	17.6	20.1	21.2	7.9			
2010-04	100.0	19.4	19.4	16.3	18.4	22.4	27.6	26.2	10.5	10.9	7.5	13.9	13.9	15.6	15.6	15.6	13.9	15.0	18.0	22.4	5.8				
2010-05	100.0	15.7	16.9	17.3	17.7	25.6	21.3	12.6	5.9	8.3	11.4	13.4	15.4	15.4	9.8	12.6	13.8	16.5	15.4	4.7					
2010-06	100.0	17.4	18.9	20.4	23.0	28.5	12.6	8.9	8.1	11.9	10.7	13.7	14.8	12.2	11.1	12.2	13.3	20.4	5.2						
2010-07	100.0	15.6	18.3	29.6	29.0	14.0	11.3	14.5	14.5	11.3	13.4	14.5	13.4	13.4	19.4	17.2	23.7	8.1							
2010-08	100.0	20.4	29.6	32.1	17.3	11.7	9.9	12.3	13.6	13.0	13.0	12.3	15.4	18.5	17.9	19.8	6.8								
2010-09	100.0	22.6	23.5	12.3	9.1	10.3	13.6	9.9	12.8	13.2	11.5	9.9	21.8	16.5	16.0	5.3									
2010-10	100.0	25.7	14.6	12.5	8.8	8.2	13.0	13.8	10.6	9.3	10.6	13.0	19.1	23.1	6.9										
2010-11	100.0	17.5	9.2	9.5	7.7	8.6	12.9	9.8	8.6	8.9	11.1	14.5	25.5	6.2											
2010-12	100.0	9.2	5.3	9.2	11.8	6.6	5.3	9.2	5.3	2.6	9.2	19.7	2.6												
2011-01	100.0	16.9	21.1	19.7	21.1	15.5	15.5	12.7	11.3	21.1	25.4	11.3													
2011-02	100.0	16.1	15.3	18.5	21.8	15.3	15.3	14.5	14.5	17.7	5.6														
2011-03	100.0	18.4	21.8	20.1	22.3	15.1	20.7	20.1	24.0	9.5															
2011-04	100.0	25.5	19.8	19.8	17.9	23.6	17.9	25.5	11.3																
2011-05	100.0	23.4	24.3	16.2	21.6	20.7	26.1	11.7																	
2011-06	100.0	23.1	21.3	26.9	20.4	28.7	8.3																		
2011-07	100.0	21.6	30.4	27.5	34.3	15.7																			
2011-08	100.0	27.4	31.1	26.4	17.0																				
2011-09	100.0	27.0	37.6	14.8																					
2011-10	100.0	32.1	15.8																						
2011-11	100.0	14.1																							
2011-12	100.0																								

Cohort Month adalah bulan pertama seorang pelanggan melakukan transaksi. Contoh: Cohort 2010-01 = semua pelanggan yang pertama kali bertransaksi di Januari 2010

Cohort Index menunjukkan jarak bulan dari bulan pertama transaksi pelanggan.
Index 0 = bulan pertama transaksi (selalu 100%)
Index 1 = 1 bulan setelah transaksi pertama
Index 2 = 2 bulan setelah transaksi pertama, dst.

Contohnya kita ambil Cohort 2010-01, cara membaca barisnya adalah:
→ 100 pelanggan pertama kali beli di Jan 2010
→ 20.6% dari mereka kembali di Feb 2010
→ 31.1% dari mereka kembali di Mar 2010
→ 30.5% dari mereka kembali di Apr 2010, dst.

Link **notebook** dan **dataset cohort_retention.csv**

Appendix E - Tech Stack & Repository

Tech Stack

Kategori	Tools
Language	Python 3.10+
Data Manipulation	Pandas, NumPy
Database	SQLite
Visualization	Matplotlib, Seaborn, Plotly
Machine Learning	Scikit-learn
Dashboard	Tableau Public
Version Control	Git + GitHub
Environment	VS Code + Jupyter Extension

Project Structure & Repository

```
customer-sales-analytics/
├── data/
│   └── cleaned/        ← cleaned CSV files
├── notebooks/
│   ├── 01_data_cleaning.ipynb
│   ├── 02_sql_exploration.ipynb
│   ├── 03_eda.ipynb
│   ├── 04_customer_analytics.ipynb
│   ├── 05_sales_analytics.ipynb
│   └── retail_analytics.ipynb
├── reports/            ← output visualisasi (.png)
├── requirements.txt
└── README.md
```

Link Repository <<<